

Comparação de Modelos de Previsão de Séries Temporais aplicados à Economia Virtual de um MMORPG

Rubens Cividati

Instituto Nacional de Telecomunicações
rubenscividati@gec.inatel.br

Marcelo V. C. Aragão

Instituto Nacional de Telecomunicações
marcelovca90@inatel.br

Abstract—This research has as initial objective to relate the variation of the MMORPG World of Warcraft virtual currency price with fluctuations of the Brazilian currency and then, to apply time series forecasting models aiming to identify the best performance(s) in short, medium, and long term scenarios. The models are detailed, and their experimental results are presented and compared in the light of metrics well disseminated in the literature. At the end of the work, the best models for predicting the prices of the virtual economy are pointed out, which can be used in applications that indicate opportunities to buy and sell items in-game.

Index Terms—Correlation analysis, foreign exchange, MMORPG, time series forecasting, virtual economy, World of Warcraft.

Resumo—Esta pesquisa tem como objetivo inicial relacionar a variação do preço da moeda virtual do MMORPG World of Warcraft com flutuações da moeda brasileira e, em seguida, aplicar modelos de previsão de séries temporais visando identificar o(s) de melhor desempenho em cenários de curto, médio e longo prazo. Os modelos são detalhados, e seus resultados experimentais são apresentados e comparados sob a luz de métricas bem disseminadas na literatura. Ao final do trabalho, são apontados os melhores modelos para prever os preços da economia virtual, podendo ser utilizados em aplicações que indiquem oportunidades de compra e venda de artigos deste jogo.

Palavras chave—Análise de correlação, câmbio estrangeiro, economia virtual, MMORPG, previsão de série temporal, World of Warcraft.

I. INTRODUÇÃO

World of Warcraft é um jogo *on-line* do gênero MMORPG (do inglês, *Massively Multiplayer Online Role-Playing Game*), desenvolvido e distribuído pela produtora Blizzard Entertainment e lançado em 2004. Em 2013 foi o MMORPG mais jogado do mundo, tendo mais de 100 milhões de contas em sua base de dados [1].

O jogo conta com um ambiente de interações entre jogadores semelhante a uma sociedade real, permitindo a realização de estudos sobre o comportamento humano, tal como o trabalho realizado por Oultram durante o “*Corrupted Blood Incident*”, primeira pandemia dentro de uma sociedade virtual [2].

Um dos elementos presentes no jogo é a casa de leilões, na qual jogadores compram e vendem equipamentos e/ou recursos do próprio jogo. Nela foram contabilizadas 2,8 milhões de trocas diárias em 2013, o que remete a duas vezes a quantidade de transações no eBay na *Cyber Monday* em 2009 [3].

Dentre a diversidade de itens presentes na casa de leilões, um se destaca por ser o único capaz de ser comercializado

por dinheiro real: a ficha de WoW, conhecida também como WoW Token. Este item pode ser obtido utilizando dinheiro real (vendido ao preço de U\$20,00) e seu objetivo pode ser:

- Renovar a mensalidade do jogo, o que é normalmente feito com um plano de inscrição mensal, trimestral ou semestral pago com dinheiro real;
- Ser comercializada entre os jogadores por uma quantia em ouro (moeda virtual de WoW);
- Ser trocada por U\$15,00 de saldo na loja da Battle.net.

Como citado anteriormente, World of Warcraft possui um sistema de assinatura, no qual o jogador paga uma quantia em dinheiro ou uma quantidade em ouro para adquirir a WoW Token e assim renovar a mensalidade. Para a moeda Real Brasileiro, a mensalidade custa R\$35,00.

O preço da WoW Token em ouro pode variar de acordo com a região geográfica que o jogador se encontra, sendo as regiões existentes no jogo: Américas, Europa, Coreia e China.

O objetivo desta pesquisa é unir as séries de dados variação do preço da WoW Token em ouro e flutuação das taxas cambiais que apresentarem o melhor índice de correlação e, em seguida, analisar a previsão para os períodos de curto, médio e longo prazo.

II. TRABALHOS RELACIONADOS

Diversos trabalhos relacionados sobre moedas virtuais dentro de jogos, análise de correlação entre séries temporais e modelos de regressão sobre taxas cambiais foram utilizados como base para realização desta pesquisa. A seguir, serão apresentados resumos com os principais aspectos dos principais trabalhos levados em consideração durante a concepção deste.

De acordo com Harambam et al. [4], em 2011 a indústria de jogos competiu diretamente com outros ramos do entretenimento, e as vendas de jogos nos Estados Unidos subiram de cerca de U\$2,6 bilhões em 1996 para U\$11,7 bilhões em 2008. Os pesquisadores também apontaram que a comercialização de moedas virtuais por moedas reais é capaz de aprimorar a experiência e imersão do jogador com o universo do jogo.

No trabalho de Tang et al. [5] foi feita a comparação entre redes neurais e métodos convencionais para previsão de dados em séries temporais. Os experimentos realizados concluíram que, para séries temporais de memória longa, ambos os modelos apresentaram resultados similares; contudo, as redes neurais se destacaram para séries de memória curta.

No estudo de De Gooijer e Hyndman [6], discorreu-se sobre a importância das pesquisas relacionadas a previsão de dados utilizando de modelos de regressão – tais como o ARIMA (do inglês, *Autoregressive Integrated Moving Average*) e o *Exponential Smoothing* – para cálculo de novas séries temporais. Também foi apresentada a evolução das métricas de avaliação para modelos de regressão, usadas para comparação e seleção de abordagens apropriadas a contextos específicos.

A pesquisa de Boothe e Glassman [7], que abordou a comparação de modelos de previsão de taxas cambiais de moedas reais, apontou os modelos de regressão autorregressivo e o RW (do inglês, *Random Walk*) como os que apresentaram melhores resultados para séries temporais, de acordo com a métrica RMSE (do inglês, *Root Mean Square Error*).

O trabalho feito por Babu e Reddy [8] explora especificamente os modelos de regressão ARIMA, redes neurais e rede Fuzzy para previsão de taxa de câmbio do dólar estadunidense, libra esterlina, euro e iene em relação às taxas de câmbio da rúpia. Na pesquisa, os autores concluíram que o modelo ARIMA apresentou melhores resultados do que os demais modelos não-lineares complexos.

Por fim, o estudo feito por Cividati et al. [9] sobre a correlação entre flutuações cambiais reais com a moeda virtual do World of Warcraft comprovou a existência de uma correlação forte e diretamente proporcional entre a moeda virtual e a taxa de câmbio real.

III. PROPOSTA

Tendo como base as correlações entre flutuações cambiais reais e a variação do preço da WoW Token em cada servidor para o período de 01/07/2019 até 31/12/2019, como foi evidenciado por Cividati et al. [9], esta pesquisa visa unificar as duas séries de dados, flutuações cambiais reais e variação do valor do preço da WoW Token, que apresentam a melhor correlação para o período de 01/01/2020 até 30/06/2020 em uma única série temporal e assim aplicar modelos de regressão para previsão de valores de curto, médio e longo prazo.

Esta pesquisa foi dividida em quatro partes: a primeira é caracterizada pela escolha da série de dados que apresenta a melhor correlação; a segunda consiste na união destas duas séries; na terceira são aplicados os modelos preditivos; por último, é feita a avaliação destes modelos.

A. Escolha da série de dados

No trabalho de Cividati et al. [9] foram utilizados dos modelos matemáticos a seguir para correlacionar a série de dados de flutuações cambiais reais e a variação do preço da WoW Token de cada região do jogo.

- Coeficiente de correlação de Pearson;
- Coeficiente de correlação de postos de Kendall;
- Coeficiente de correlação de postos de Spearman.

Todas essas três medidas fornecem um índice que varia de -1 a $+1$, no qual 0 indica nenhuma correlação entre dois conjuntos de dados. Valores -1 ou $+1$ implicam em uma exata correlação linear. Correlações positivas indicam que ambos valores estão diretamente ligados, como por exemplo, quando x aumenta; y também aumenta. Em contrapartida, um

índice negativo indica que ambos os valores estão inversamente ligados, como por exemplo, quando x aumenta; y diminui.

A tabela I mostra as correlações entre as flutuações cambiais reais (Moeda) e variação do preço da WoW Token (Região) para o período de 01/07/2019 a 31/12/2019. As séries de dados Américas e Real brasileiro foram as que apresentaram os maiores índices de correlação.

TABELA I
CORRELAÇÃO ENTRE WoW TOKEN E MOEDAS REAIS (01/07/2019 - 31/12/2019)

Região	Moeda	Pearson	Kendall	Spearman
Américas	Real brasileiro	0,81	0,47	0,65
Europa	Euro	0,55	0,28	0,46
China	Renminbi	0,74	0,36	0,56
Coreia	Won sul-coreano	-0,10	-0,05	-0,09

A tabela II também mostra as correlações entre a Moeda e Região, contudo, para o período de 01/01/2020 a 30/06/2020. As séries de dados Américas e Real brasileiro também apresentaram os maiores índices de correlação (mesmo que inversamente proporcionais).

TABELA II
CORRELAÇÃO ENTRE WoW TOKEN E MOEDAS REAIS (01/01/2020 - 30/06/2020)

Região	Moeda	Pearson	Kendall	Spearman
Américas	Real brasileiro	-0,93	-0,81	-0,94
Europa	Euro	-0,07	-0,05	-0,02
China	Renminbi	0,52	0,29	0,47
Coreia	Won sul-coreano	-0,83	-0,5	-0,69

De acordo com os resultados encontrados nas tabelas I e II, a Região e Moeda alvo desta pesquisa são respectivamente Américas e Real brasileiro, devido às taxas de correlação.

B. União das séries de dados

Foi elaborado uma equação matemática para unificar as séries temporais Américas e Real brasileiro. A série de dados s representa quanto mil moedas de ouro valem em dinheiro real. A equação pode ser compreendida por:

$$s = \frac{M_i * 20}{R_i} \quad (1)$$

- s : nova série de dados;
- M_i : valor da moeda Real brasileiro;
- R_i : valor do preço da WoW Token em ouro;
- 20: constante que converte o preço da WoW Token em dólares para o valor em Real brasileiro

C. Aplicação dos modelos preditivos

A partir da nova série de dados s , aplicam-se os seguintes modelos preditivos:

- Naive Forecaster: modelo de previsão de dados que pode utilizar de três abordagens ingênuas para o cálculo de previsão do próximo valor:
 - last: O último valor da série temporal é considerado o próximo valor;
 - mean: O próximo valor é calculado através da média de todos os valores anteriores;
 - drift: O valor previsto é dado por uma reta entre o primeiro e o último valores da série temporal.

- ARIMA: (do inglês, *Autoregressive Integrated Moving Average*) é uma generalização do modelo ARMA (do inglês, *Autoregressive Moving Average*). Estes modelos podem ser especialmente eficazes nos casos em que os dados mostram evidências de não estacionariedade [10]. As abordagens utilizadas nesta pesquisa foram:
 - bfgs: (do inglês, *Broyden-Fletcher-Goldfarb-Shanno*) é um método iterativo para resolver problemas de otimização não linear irrestrita [11];
 - powell: algoritmo para otimizar uma função de várias variáveis que não faz uso de derivadas [12].
- Auto-ARIMA: este processo busca identificar os melhores parâmetros para um modelo ARIMA. As abordagens utilizadas nesta pesquisa foram:
 - nm: (do inglês, *Nelder-Mead*) é um método numérico comumente aplicado usado para encontrar o mínimo ou o máximo de uma função [13];
 - cg: (do inglês, *Conjugate gradient method*) é um algoritmo para a solução numérica de sistemas de equações lineares de matriz positiva definida e simétrica [14].
- Holt-Winters: usa suavização exponencial simples sem componentes de tendência e sazonalidade [15].
- Theta: o método é uma composição de outros métodos que têm como objetivo decompor a série temporal em outras duas séries temporais [16].
- Polynomial Trend: previsão de dados de série temporal com uma tendência polinomial possui configurações padrão que treinam um modelo de regressão linear com uma transformação polinomial de 1º grau. Foram utilizados polinômios de grau 4 para previsões de curto e médio prazo, e de grau 1 para longo prazo.

D. Avaliação dos modelos

Tendo os valores de previsão calculados pelos modelos apresentados na seção anterior, calculam-se as seguintes métricas de avaliação sobre estes dados [17]:

- MAE (do inglês, *Mean Absolute Error*): é a diferença absoluta entre o valor medido e o valor calculado. Esta métrica é dada pela equação 2:

$$MAE = \frac{1}{n} \sum_{i=1}^n |A_t - F_t| \quad (2)$$

- A_t : valor real;
- F_t : valor calculado;
- n : quantidade de elementos.
- RMSE (do inglês, *Root Mean Square Error*): é uma medida usada que calcula “a raiz quadrática média” dos erros entre valores observados (reais) e predições (hipóteses). Esta métrica é dada pela equação 3:

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (A_t - F_t)^2} \quad (3)$$

- A_t : valor real;
- F_t : valor calculado;
- n : quantidade de elementos.
- MAPE (do inglês, *Mean Absolute Percentage Error*): consiste em um valor de ponto flutuante não negativo no

qual o melhor valor é 0,0. Não há limite para a magnitude do erro, especialmente quando os valores de A_t estão próximos de zero. Nesses casos, a função retorna um valor grande. Esta métrica é dada pela equação 4:

$$MAPE = \frac{1}{n} \sum_{i=1}^n \left| \frac{A_t - F_t}{A_t} \right| \quad (4)$$

- A_t : valor real;
- F_t : valor da previsão;
- n : quantidade de elementos.
- SMAPE: em contraste com MAPE, o SMAPE (do inglês, *Symmetric Mean Absolute Percentage Error*) possui um limite inferior e um limite superior. Esta métrica é dada pela equação 5:

$$SMAPE = \frac{100\%}{n} \sum_{i=1}^n \frac{|F_t - A_t|}{(|A_t| + |F_t|)/2} \quad (5)$$

- A_t : valor real;
- F_t : valor da previsão;
- n : quantidade de elementos.
- MASE: essa medida de erro sem escala (do inglês, *Mean Absolute Scaled Error*) pode ser usada para comparar métodos de previsão em uma única série, e também para comparar a precisão da previsão entre as séries. Essa métrica é adequada para séries de demanda intermitente porque nunca fornece valores infinitos ou indefinidos [18]. Esta métrica é dada pela equação 6:

$$MASE = média \left(\left| \frac{e_t}{\frac{1}{n-1} \sum_{i=1}^n |Y_i - Y_{i-1}|} \right| \right) \quad (6)$$

- numerador: erro de previsão;
- denominador: erro médio absoluto.

IV. TECNOLOGIAS UTILIZADAS

O trabalho foi desenvolvido em Python, linguagem de programação interpretada de alto nível, multiparadigma, podendo atuar de forma orientada a objetos, tendo sua licença livre, lançada por Guido van Rossum em 1991 e mantida de forma colaborativa e aberta atualmente [19].

A linguagem dispõe de um acervo de pacotes auxiliares que facilitam a prototipação e agilizam o desenvolvimento de projetos devido à grande abstração e disponibilidade de funções implementadas pela comunidade. Os pacotes utilizados foram:

- Anaconda: distribuição de Python e R para análise de dados que visa simplificar o gerenciamento de pacotes e ambientes de desenvolvimento.
- Numpy: este pacote possui uma variedade de rotinas para operações rápidas em vetores multidimensionais, incluindo matemática, lógica, manipulação de forma, classificação, seleção, entrada/saída, transformadas discretas de Fourier, álgebra linear básica, operações estatísticas básicas, simulação aleatória etc. [20][21].
- Pandas: ferramenta de manipulação e análise de dados de código aberto rápida, poderosa, flexível e amigável. [22].
- Sktime: fornece implementações para previsão de séries temporais e ferramentas compatíveis com a biblioteca scikit-learn para construir, ajustar e validar modelos aplicáveis a diversos problemas de aprendizagem.

TABELA III
PREVISÃO DOS VALORES PARA CURTO PRAZO (1 DIA).

Modelo	Valores Calculados
Naïve (last)	0.909
Naïve (mean)	0.624
Naïve (drift)	0.910
ARIMA	0.909
Auto-ARIMA	0.909
Holt-Winters	0.909
Theta	0.910
Polynomial	0.880

V. DISCUSSÃO DOS RESULTADOS

As avaliações dos modelos preditivos foram divididas em três cenários, sendo eles:

- Cenário 1: horizonte de previsão de curto prazo (1 dia);
- Cenário 2: horizonte de previsão de médio prazo (7 dias);
- Cenário 3: horizonte de previsão de longo prazo (30 dias).

Para cada cenário, foi(ram) removido(s) o(s) modelo(s) cujo(s) desempenho(s) (em termos de MAPE e SMAPE, por serem facilmente interpretados já que se dão em escalas percentuais) foi(ram) considerado(s) anomalia(s) de acordo com a análise de amplitude interquartil. Em seguida, os resultados foram dispostos em um histograma com o número de compartimentos obtido de acordo com a regra de Freedman-Diaconis. Desta forma, foi possível discriminar os melhores, médios e piores modelos em cada cenário. [23]

A. Cenário 1

As previsões para o horizonte de curto prazo (1 dia) e os valores de erro estão dispostos na tabelas e III e IV, respectivamente.

TABELA IV
RESULTADOS DAS MÉTRICAS SOBRE OS MODELOS PREDITIVOS PARA O HORIZONTE DE PREVISÃO DE CURTO PRAZO (1 DIA).

Modelo	MAE	RMSE	MAPE	SMAPE	MASE
Naïve (last)	0.002	0.002	0.19%	0.19%	0.250
Naïve (mean)	0.286	0.286	45.83%	37.28%	40.989
Naïve (drift)	0.001	0.001	0.09%	0.09%	0.123
ARIMA	0.002	0.002	0.20%	0.20%	0.261
Auto-ARIMA	0.002	0.002	0.20%	0.20%	0.265
Holt-Winters	0.002	0.002	0.19%	0.19%	0.250
Theta	0.000	0.000	0.05%	0.05%	0.059
Polynomial	0.031	0.031	3.49%	3.43%	4.400

Classificação dos modelos:

- Modelos recomendados: Theta e Naïve (drift);
- Modelos aceitáveis: Holt-Winters, Naïve (last), ARIMA e Auto-ARIMA
- Modelos não recomendados: Naïve (mean) e Polynomial.

A partir dos resultados encontrados para o horizonte de previsão de curto prazo (vide tabela IV), os modelos recomendados são Theta e Naïve (drift), por terem apresentado as menores taxas de erro MAPE e SMAPE. Os modelos Holt-Winters, Naïve (last), ARIMA e Auto-ARIMA são considerados aceitáveis por terem produzido taxas de erro intermediárias; os modelos Naïve (mean) e Polynomial não são recomendados devido as suas altas taxas relativas de erro.

B. Cenário 2

As previsões para o horizonte de médio prazo (7 dias) estão ilustradas nos gráficos das figuras 1 e 2 (zoom), com os valores de erro dispostos na tabela V.




Fig. 1. Gráfico da previsão de médio prazo (7 dias).




Fig. 2. Zoom do gráfico da previsão de médio prazo (7 dias).

TABELA V
RESULTADOS DAS MÉTRICAS SOBRE OS MODELOS PREDITIVOS PARA O HORIZONTE DE PREVISÃO DE MÉDIO PRAZO (7 DIAS).

Modelo	MAE	RMSE	MAPE	SMAPE	MASE
Naïve (last)	0.018	0.020	2.02%	2.00%	2.592
Naïve (mean)	0.283	0.283	45.59%	37.11%	40.813
Naïve (drift)	0.015	0.017	1.71%	1.70%	2.208
ARIMA	0.018	0.020	2.02%	2.00%	2.597
Auto-ARIMA	0.024	0.027	2.70%	2.66%	3.435
Holt-Winters	0.018	0.020	2.02%	2.00%	2.592
Theta	0.016	0.017	1.75%	1.73%	2.252
Polynomial	0.023	0.025	2.58%	2.56%	3.323

Classificação dos modelos:

- Modelos recomendados: Theta e Naïve (drift);
- Modelos aceitáveis: Holt-Winters, Naïve (last) e ARIMA;
- Modelos não recomendados: Naïve (mean), Polynomial e Auto-ARIMA.

Para a previsão de médio prazo (conforme tabela V), os modelos recomendados são Theta e Naïve (drift), por terem apresentado as menores taxas de erro MAPE e SMAPE. Os modelos Holt-Winters, Naïve (last) e ARIMA são considerados aceitáveis por terem produzido taxas de erro intermediárias; os modelos Naïve (mean), Polynomial e Auto-ARIMA não são recomendados devido as suas altas taxas relativas de erro.

C. Cenário 3

As previsões para o horizonte de longo prazo (7 dias) estão ilustradas nos gráficos das figuras 3 e 4 (zoom), com os valores de erro dispostos na tabela VI.




Fig. 3. Gráfico da previsão de longo prazo.

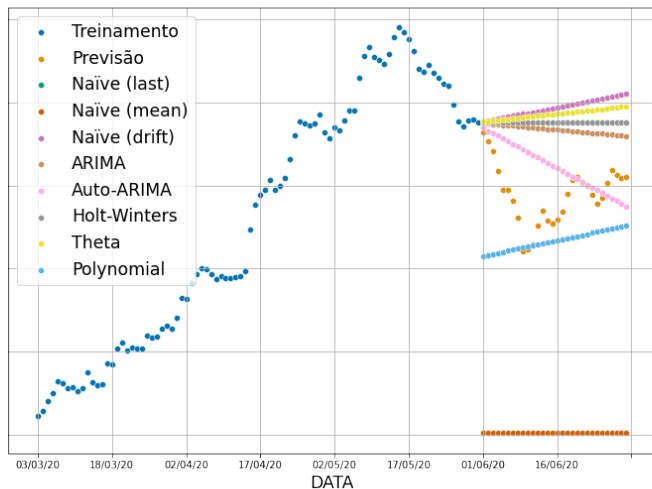


Fig. 4. Zoom do gráfico da previsão de longo prazo (30 dias).

TABELA VI
RESULTADOS DAS MÉTRICAS SOBRE OS MODELOS PREDITIVOS PARA O
HORIZONTE DE PREVISÃO DE LONGO PRAZO (30 DIAS).

Modelo	MAE	RMSE	MAPE	SMAPE	MASE
Naïve (last)	0.087	0.094	8.94%	9.43%	13.404
Naïve (mean)	0.287	0.289	47.67%	38.41%	44.048
Naïve (drift)	0.105	0.111	10.59%	11.26%	16.179
ARIMA	0.079	0.086	8.16%	8.58%	12.133
Auto-ARIMA	0.044	0.056	4.70%	4.87%	6.720
Holt-Winters	0.087	0.094	8.94%	9.43%	13.404
Theta	0.098	0.104	9.91%	10.49%	15.007
Polynomial	0.056	0.066	6.71%	6.40%	8.558

Classificação dos modelos:

- Modelos recomendados: Auto-ARIMA e Polynomial;
- Modelos aceitáveis: Holt-Winters, ARIMA e Naïve (last);
- Modelos não recomendados: Naïve (mean) e Naïve (drift).

Analisando o horizonte de previsão de longo prazo (tabela VI), os modelos recomendados são Auto-ARIMA e Polynomial, por terem apresentado as menores taxas de erro MAPE e SMAPE. Os modelos Holt-Winters, ARIMA e Naïve (last) são considerados aceitáveis por terem produzido taxas de erro intermediárias; os modelos Naïve (mean) e Naïve (drift) não são recomendados devido as suas altas taxas relativas de erro.

É perceptível que, quanto maior o horizonte de previsão, maiores são as taxas de erro; portanto, visando ter o menor erro possível e considerando que o cenário típico para compra e venda de itens no jogo é de um dia (pois nestes casos o retorno do investimento acontece rapidamente), os modelos Theta e Naïve (drift) são os mais indicados para esta tarefa.

VI. CONCLUSÃO

Este artigo propôs unificar as séries temporais de flutuações cambiais reais e variação do valor do preço da WoW Token apresentadas por Cividati et al. [9], aplicar modelos de previsão sobre a nova série de dados e avaliar os resultados encontrados para os horizontes de previsão de curto, médio e longo prazos.

Utilizando diversas medidas estatísticas para avaliar numericamente os resultados produzidos pelos oito modelos de previsão considerados, observa-se que os mais recomendados seriam o Theta e o Naïve (drift) para previsão de curto e médio prazos, e Auto-ARIMA e Polynomial para longo prazo. Os modelos Naïve (mean) e Polynomial apresentaram péssimos resultados em todos os três horizontes de previsão. Os demais modelos apresentaram desempenhos medianos.

São sugeridos os seguintes pontos para trabalhos futuros:

- Levantar em consideração, além do preço da WoW Token e das taxas de câmbio das moedas reais, a cotação das ações da Blizzard Entertainment (ativo ATVI).
- Levantar em consideração a quantidade de jogadores ativos por região como um aspecto de ponderação (nas etapas de concepção da série de dados, treinamento e/ou predição);
- Considerar uma série temporal mais extensa, para os modelos possam utilizar mais dados na generalização e, possivelmente, obter uma menor taxa de erro de previsão;
- Realizar a otimização de hiperparâmetros dos modelos visando produzir previsões mais robustas;
- Conduzir o treinamento dos modelos em regime de validação cruzada de modo a evitar enviesamento e sobreajuste (*overfitting*);

- Desenvolver uma plataforma para exibição dos *insights* obtidos, fornecendo aos jogadores dicas de quando um item em particular deve ser comprado e/ou vendido para maximização de lucro e/ou minimização de prejuízo.

VII. AUTORES



Rubens Cividati é técnico em Informática pelo Instituto Federal do Sul de Minas Gerais Campus Inconfidentes em 2016 e graduando em Engenharia de Computação pelo Instituto Nacional de Telecomunicações (Inatel). É estagiário em *DevOps* na empresa 4Intelligence e administrador de campeonatos de jogos eletrônicos pela empresa MVP Network. Possui interesse nas áreas de análise de dados e desenvolvimento de jogos.



Marcelo Vinícius Cysneiros Aragão é graduado em Engenharia de Computação pelo Instituto Nacional de Telecomunicações (Inatel) em 2014 e Mestre em Ciência e Tecnologia da Computação pela Universidade Federal de Itajubá em 2018. Trabalhou de 2011 a 2018 no Inatel Competence Center, mais recentemente como Especialista em Sistemas, onde atuou principalmente como desenvolvedor de soluções de *Business Support Systems* (BSS) em ambiente de integração contínua. É professor de disciplinas da graduação, como Inteligência Computacional e Redes Neurais, coordenador do curso de pós-graduação em Desenvolvimento de Aplicações para Dispositivos Móveis e *Cloud Computing* e doutorando em Engenharia de Telecomunicações no Inatel. Possui interesse nas áreas de aprendizado de máquina, ciência de dados e engenharia de *software*.

REFERÊNCIAS

- [1] Blizzard Entertainment. *World of Warcraft - 1º Infográfico Oficial - Blizzard Entertainment*. Dez. de 2013. URL: <https://bit.ly/blizz-infog>.
- [2] Stuart Oultram. “Virtual plagues and real-world pandemics: Reflecting on the potential for online computer role-playing games to inform real world epidemic research”. Em: *Medical Humanities* 39.2 (2013), pp. 115–118.
- [3] Blizzard Entertainment. *Ficha de WoW - World of Warcraft — Loja Blizzard*. 2020. URL: <https://bit.ly/blizz-wowtoken>.
- [4] Jaron Harambam, Stef Aupers e Dick Houtman. “Game over? Negotiating modern capitalism in virtual game worlds”. Em: *European Journal of Cultural Studies* 14.3 (2011), pp. 299–319.
- [5] Zaiyong Tang, Chrys de Almeida e Paul A. Fishwick. “Time series forecasting using neural networks vs. Box-Jenkins methodology”. Em: *Simulation* 57.5 (1991), pp. 303–310.
- [6] Jan G. De Gooijer e Rob J. Hyndman. “25 years of time series forecasting”. Em: *International Journal of Forecasting* 22.3 (2006), pp. 443–473.
- [7] Paul Boothe e Debra Glassman. “Comparing exchange rate forecasting models: Accuracy versus profitability”. Em: *International Journal of Forecasting* 3.1 (1987), pp. 65–79.
- [8] AS Babu e SK Reddy. “Exchange Rate Forecasting using ARIMA, Neural Network and Fuzzy Neuron”. Em: *Neural Network and Fuzzy Neuron, Journal of Stock & Forex Trading* 4.3 (2015), pp. 01–05.
- [9] Rubens Cividati, Isabella Capistrano e Marcelo Aragão. “Análise de Correlação entre Flutuações Cambiais Reais e Moeda Virtual de um MMORPG”. Em: *Anais do Congresso de Iniciação Científica do Inatel - Incitel 2020*. Jun. de 2020, pp. 40–45.
- [10] George EP Box, Gwilym M Jenkins, Gregory C Reinsel e Greta M Ljung. *Time series analysis: forecasting and control*. John Wiley & Sons, 2015.
- [11] R. Fletcher. *Practical Methods of Optimization*. A Wiley-Interscience publication v. 2. Wiley, 1987.
- [12] Michael JD Powell. “An efficient method for finding the minimum of a function of several variables without calculating derivatives”. Em: *The computer journal* 7.2 (1964), pp. 155–162.
- [13] John A Nelder e Roger Mead. “A simplex method for function minimization”. Em: *The computer journal* 7.4 (1965), pp. 308–313.
- [14] Magnus Rudolph Hestenes, Eduard Stiefel et al. *Methods of conjugate gradients for solving linear systems*. Vol. 49. 1. NBS Washington, DC, 1952.
- [15] Peter R Winters. “Forecasting sales by exponentially weighted moving averages”. Em: *Management science* 6.3 (1960), pp. 324–342.
- [16] Vassilis Assimakopoulos e Konstantinos Nikolopoulos. “The theta model: a decomposition approach to forecasting”. Em: *International journal of forecasting* 16.4 (2000), pp. 521–530.
- [17] Rob J Hyndman e George Athanasopoulos. *Forecasting: principles and practice*. OTexts, 2018.
- [18] Rob J. Hyndman e Anne B. Koehler. “Another look at measures of forecast accuracy”. Em: *International Journal of Forecasting* 22.4 (2006), pp. 679–688.
- [19] Guido Van Rossum et al. “Python Programming Language.” Em: *USENIX annual technical conference*. Vol. 41. 2007, p. 36.
- [20] Travis E Oliphant. *A guide to NumPy*. Vol. 1. Trelgol Publishing USA, 2006.
- [21] Stéfan van der Walt, S Chris Colbert e Gael Varoquaux. “The NumPy array: a structure for efficient numerical computation”. Em: *Computing in Science & Engineering* 13.2 (2011), pp. 22–30.
- [22] Wes McKinney. “Data Structures for Statistical Computing in Python”. Em: *Proceedings of the 9th Python in Science Conference*. Ed. por Stéfan van der Walt e Jarrod Millman. 2010, pp. 51–56.
- [23] James D. Triveri. *Determining Histogram Bin Width using the Freedman-Diaconis Rule*. Mar. de 2019. URL: <http://www.jtrive.com/determining-histogram-bin-width-using-the-freedman-diaconis-rule.html>.